

[31]

$$1) a(x) = \begin{cases} 1, & f(x) \geq 0 \\ -1, & f(x) < 0 \end{cases}$$

$$a(x) = \text{sign}(f(x))$$

$$f(x) = w_0 + w_1 x_1 + \dots + w_n x_n + a_0 + \langle w, x \rangle$$

$$2) f(x) = g(f(x))$$

$$a(x) \neq y \Leftrightarrow K \neq 0$$

Если  $K \neq 0$ , то не существует классификатора

3) Добавление  $w_0 = 1$  гарантирует признак «вытеснен», «вытеснен»  
высв. добавляется  $w_0$

$$4) Q = \frac{1}{\epsilon} \sum_{i=1}^{\epsilon} I[a(x_i) \neq y_i] = \frac{1}{\epsilon} \sum_{i=1}^{\epsilon} I[K_i \neq 0]$$

Для минимизации алгоритма Q=0 (все предсказания верны)

5) Если  $w_0 = 0$ , тогда  $K_0 = 0$  и  $Q = 0$

$$6) Q = \frac{1}{\epsilon} \sum_{i=1}^{\epsilon} L(M)$$

7) Ф.л. потерь  $L(a, x)$  есть величина сходки алгоритма а на  
объекте  $x$

$L(a, x) \geq 0$  и не возрастает для или классификации

$$8) L(M) = [1 - M]$$

9) Регрессор штрафует за ошибку веса признаков, штраф  
за ошибку

$$L_1 - \text{рег-фр} \quad i = \sum_{k=1}^n |w_k|$$

$L_2$  - пар-р рег-фр или, тем же образом, тем  
сильнее штрафует

$$L_2 - \text{рег-фр} \quad i = \sum_{k=1}^n w_k^2$$

регрессора

10)  $Q(a(x^1), x^1)$  - обучающая последовательность  $x^1$  и  $x^1$  - класс с вытеснен

Если мы не переобучим, то значение будет расти. Переобучение - это про-  
зреть, если пар-р рег-фр или (все признаки) входят в опре-  
деленное правило Регрессии как раз будет с этим

11) Все эти точки проецируются сильнее возрастает по-  
лучающая функция аппроксимированного минимизирующего правила.  
Данный пар-р подавляет все остальные - переобучение

12) Как увеличивается при прирост или возмездии пар пох (вход) на распределенные финансы

13) Для алгоритма с регуляризатором, то регуляризатор увеличивает с точностью

14) Величина для варианта

Первый - переходящее без регуляризации не превосходит  $\frac{1}{2}$  для всех

Второй - случай оптимального переходящего

15) Термин Вектора для задачи дилеммы классификации

Обозначим  $TP$  - количество правильных ответов  $+1$  и  $FP$   $+1$ ,

$FN$  - пропуск  $-1$ ,  $FN$   $+1$

$TN$  - пропуск  $-1$ ,  $TN$   $-1$

$FP$  - пропуск  $+1$ ,  $FP$   $-1$ ,  $FP$   $+1$

$$accuracy = \frac{TP + TN}{P + N}, precision = \frac{TP}{TP + FP}, recall = \frac{TP}{P}$$

16) ROC-кривая графика зависимости TPR от FPR, где  $TPR = \frac{TP}{P}$ ,  $FPR = \frac{FP}{N}$

Метрика AUC - площадь под ROC-кривой

17) ROC-кривая строится по набору  $\{(FPR_i, TPR_i)\}_{i=1}^L$ , называемого врезте сгруппированная.

1. Верифицируем входные  $x^i$  по значению функции  $A(x, w)$

2.  $(FPR_0, TPR_0) = (0, 0)$

for  $i$  in range  $(1, L)$

if  $(y_i = -1)$

$$(FPR_i, TPR_i) = (FPR_{i-1} + \frac{1}{L}, TPR_{i-1})$$

else

$$(FPR_i, TPR_i) = (FPR_{i-1}, TPR_{i-1} + \frac{1}{L})$$

[3.2]  $x > y$  - верно или нет

$p(x, y|w)$  - парама-а модель совместной плотности распределения объектов и классов

Введем  $p(w, \delta)$  - парама-а модель априорного распределения  $\delta$  - гиперпараметры

Если считать, что выборка  $w$  и  $\delta$  порождена каждой из пар объектов  $p(x, y|w)$  с вероятностью  $p(w, \delta)$

Приходим к принципу максимума правдоподобия:

$$L_2(w, x^i) = \ln p(x^i, w, \delta) = \sum_{j=1}^J \ln(p(x_j, y_j | w)) + \ln p(w, \delta) \rightarrow \max_w$$

$$\text{Таким образом } L(y_i, l(x_i, w)) = -\ln p(x_i, y_i | w)$$

$$\delta V(w) = \ln p(w, \delta)$$

$$\text{Функция } Q(w, x^i) = \sum_{j=1}^J L(y_j, l(x_j, w)) + \delta V(w) \rightarrow \max_w$$

принцип минимизации функции потерь минимизации риска

Таким образом, при  $p \propto V(w)$  имеет вид  $\delta$  имеет априорного распределения

$L_1$  - при  $p$  совпадает с априорным распределением Лапласа

$$p(w, c) = \frac{1}{(2c)^n} \exp\left(-\frac{\|w\|_1}{c}\right)$$

$$-\ln p(w, c) = \frac{1}{c} \sum_{j=1}^n |w_j| + \text{const}(w)$$

$L_2$  - при  $p$  совпадает с априорным распределением Гаусса

$$p(w, \sigma) = \frac{1}{(2\pi\sigma)^n} \exp\left(-\frac{\|w\|^2}{2\sigma}\right)$$

$$-\ln p(w, \sigma) = \frac{1}{2\sigma} \|w\|^2 + \text{const}(w)$$

$$[3.4] \quad X = \mathbb{R}^n, Y = \{-1, 1\}$$

$$a(x) = \text{sign}\left(\sum_{j=1}^J w_j x_j - w_0\right) = \text{sign}(\langle w, x \rangle - w_0)$$

$w$  - в-р весов

$x = (x^1, \dots, x^n)$  - признаковое описание объекта

Предположим, что линейно разделяем  $J$  классов  $w_0, w_1, \dots, w_J$

$$Q(w, w_0) = \sum_{i=1}^J [y_i (\langle w, x_i \rangle - w_0) \leq 0] = 0$$

Цели оптимальное разделение классов на  $J$  классов

при  $p$  совпадает с априорным распределением Лапласа

$$\text{при } y_i (\langle w, x_i \rangle - w_0) = 1$$

при  $p$  совпадает с априорным распределением Гаусса

Ширину полосы

$$\langle (x_i - x_j, \frac{w}{\|w\|}) \rangle = \frac{\langle w, x_i \rangle - \langle w, x_j \rangle}{\|w\|} = \frac{(w_0 + 1) - (w_0 - 1)}{\|w\|} = \frac{2}{\|w\|}$$

Таким образом, ширина полосы макс. при мин. норме  $w$

$$\text{Максимизация: } \begin{cases} \frac{1}{2} \|w\|^2 \rightarrow \min_{w, w_0} \\ y_i (\langle w, x_i \rangle - w_0) \geq 1, i = 1, \dots, J \end{cases}$$

В задаче или разрабатывается водород  $y_i (\langle w, x_i \rangle - w_0)$  не обязательно  
имеется. Основная задача с  $n$  функциями  $f_i$  и  $g_i$  и  $n$  функций  $f_i$  и  $g_i$   
за симметрично сходящейся функции.

$$\begin{cases} \frac{1}{2} \|w\|^2 + c \sum_{i=1}^L E_i \rightarrow \min_{w, w_0, E} \\ y_i (\langle w, x_i \rangle - w_0) \geq 1 - E_i, i = 1, \dots, L \\ E_i \geq 0 \end{cases}$$

Преобразуем задачу на  $E_i$ :

$$\begin{cases} E_i \geq 1 - y_i (\langle w, x_i \rangle - w_0) = 1 - \mu_i (w, w_0) \\ E_i \geq 0 \end{cases}$$

Минимум  $E_i = (1 - \mu_i (w, w_0))_+$

Получаем безусловную задачу оптимизации:

$$\frac{1}{2} \|w\|^2 + c \sum_{i=1}^L (1 - \mu_i (w, w_0))_+ \rightarrow \min_{w, w_0}$$

[3.4] Рассмотрим квадратичную форму:

$$K(x, y) = \langle x, y \rangle^2 = (x_1 y_1 + x_2 y_2)^2 = x_1^2 y_1^2 + x_2^2 y_2^2 + 2x_1 y_1 x_2 y_2 =$$

$$= \langle (x_1^2, x_2^2, \sqrt{2} x_1 x_2), (y_1^2, y_2^2, \sqrt{2} y_1 y_2) \rangle$$

Получим отображение  $\psi$  из  $\mathbb{R}^3$  в  $\mathbb{R}^3$ :

$$\psi(x_1, x_2) \rightarrow (x_1^2, x_2^2, \sqrt{2} x_1 x_2)$$

Линейное  $\pi$  в  $\mathbb{R}^3$  имеет вид

$$\langle (x_1^2, x_2^2, \sqrt{2} x_1 x_2), (w_1, w_2, w_3) \rangle + w_0 = w_1 x_1^2 + w_2 x_2^2 + w_3 \sqrt{2} x_1 x_2 + w_0 = 1$$

$$\text{Положим } w = (1, 2, 0), w_0 = -3, \text{ тогда}$$

$$(1) \quad x_1^2 + 2x_2^2 - 3 = 0$$

[3.5] Теорема Кармуана-Куна-Таккера

$$\begin{cases} f(x) \rightarrow \min_x \\ g(x) \leq 0 \end{cases} \Leftrightarrow \begin{cases} \exists \lambda \geq 0, \mu \geq 0 \\ \lambda f(x) + \mu g(x) = 0, \mu g(x) = 0, \mu \geq 0 \end{cases}$$

$$\lambda f(x) + \mu g(x) \rightarrow \min_x$$

Оп-е  $\lambda$ -нормы все по всем  $x$  и  $y$ :

$$\begin{cases} Q_n(w) = \|Fw - y\|^2 \rightarrow \min_w \\ \sum_{j=1}^n |w_j| \leq \bar{t} \end{cases} \Leftrightarrow \begin{cases} Q(w) = \|Fw - y\|^2 \rightarrow \min_w \\ \sum_{j=1}^n |w_j| - \bar{t} \leq 0 \end{cases}$$

то т.е. ККТ применим к задаче:



$$\begin{cases} Q(\omega) = \|F\omega - y\|^2 + \lambda \left( \sum_{j=1}^p |\omega_j| - i \right) \\ \lambda > 0 \end{cases} \quad \begin{cases} Q(\omega) = \|F\omega - y\|^2 + \lambda \sum_{j=1}^p |\omega_j| + \text{const} \\ \lambda > 0 \end{cases} \quad \begin{cases} Q(\omega) = \|F\omega - y\|^2 + \lambda \sum_{j=1}^p |\omega_j| = i \end{cases}$$

Т.е. приходим к задаче с греб. ем штрафом с  $\ell_1$ -нормой.